

Privatnost u doba veštačke inteligencije

Seminarski rad iz kursa Računarstvo i društvo

Marko Lazarević

Matematički fakultet
Univerzitet u Beogradu

September 27, 2025

1. Uvod
2. Curenje podataka u sistemima veštačke inteligencije
3. Manipulacija i lažiranje podataka
4. Pravni okviri i regulative za zaštitu privatnosti
5. Strategije za zaštitu privatnosti u eri veštačke inteligencije
6. Zaključak i budući izazovi

Veštačka inteligencija i njen značaj

- Veštačka inteligencija (eng. *Artificial intelligence* - **AI**)
 - Omogućava mašinama da obavljaju zadatke koji bi inače zahtevali ljudsku inteligenciju
 - Prepoznavanje govora, razumevanje slika, predviđanje ponašanja, donošenje odluka
- Značaj veštačke inteligencije
 - Poslovne primene
 - Automatizacija procesa
 - Edukacija i istraživanje
 - Zabava i kreativnost
- Veštačka inteligencija postala je neizostavni deo današnjice

Izazovi i zabrinutosti u vezi sa AI

- Pravna i etička pitanja
- Obrada velike količine podataka
- Rizici
 - Prikupljanje osjetljivih podataka – korišćenje zdravstvenih, finansijskih i biometrijskih podataka
 - Prikupljanje bez pristanka – podaci prikupljeni bez znanja ili saglasnosti korisnika
 - Korišćenje bez dozvole – podaci upotrebljeni u svrhe koje nisu prethodno obelodanjene
 - Nadgledanje i pristrasnost – analiza podataka sa kamera i veb kolačića uz rizik od pristrasnih odluka
 - Ekstrakcija podataka – napadi poput prompt injekcije radi otkrivanja poverljivih informacija
 - Curenje podataka – nenamerno izlaganje privatnih informacija od strane AI sistema

Curenje podataka u sistemima veštačke inteligencije

- Smanjena tačnost modela zbog pogrešnih ili nepotpunih podataka
- Pogrešna evaluacija i optimistični rezultati tokom testiranja
- Gubljenje vremena i resursa zbog ponovnog treniranja modela
- Rizik od curenja poverljivih ili privatnih podataka
- Generativni modeli (npr. ChatGPT) mogu nenamerno izlagati korisničke informacije

Curenje podataka u generativnim alatima

- Primena u odbrani: analiza logova, mrežnog saobraćaja i edukacija korisnika
- Primena u napadu: olakšava pripremu sajber napada čak i bez stručnog znanja
- Primeri stvarnog curenja podataka: Samsung, MediSecure, Stack Overflow/OpenAI
- Opasnost da korisnik izvlači poverljive informacije iz modela
- Preporuka: ograničena upotreba GenAI alata u poslovnom okruženju i pažljivo upravljanje podacima

Lažiranje fotografija (Deepfakes)

- Generativni AI modeli omogućavaju kreiranje uverljivih fotografija i video-snimaka
- Primer: **Clearview.AI** koristi javno dostupne slike za prepoznavanje lica
- Umetnica je otkrila da su njeni medicinski podaci korišćeni u skupovima podataka za treniranje modela **LAION**
- Incident *QTCinderella* — AI deepfake pornografija širi se bez saglasnosti
- Aplikacija **Faceswap** omogućava jednostavno lažiranje lica; dostupna široj javnosti
- Posledice: ozbiljna pretnja privatnosti i integritetu pojedinaca

- AI omogućava širenje lažnih vesti, sada i u video formatu
- Deepfake video može prevariti veliki broj ljudi, što otežava verifikaciju informacija
- Studija: studenti prepoznaju lažne video sadržaje, ali postoji rizik od zavaravanja velikog broja ljudi
- Preporuke: zatvaranje pristupa softverima, edukacija i podizanje svesti o lažnim sadržajima
- AI alati se kontinuirano razvijaju i omogućavaju sve lakšu manipulaciju i lažiranje

- AI može generisati uverljive, ali lažne naučne radove
- Primer: GPT-2 i ChatGPT korišćeni za generisanje lažnih članaka
- AI detektori (Content at Scale, OpenAI) mogu prepoznati generisani tekst, ali nisu savršeni
- Problemi: kredibilitet rada, intelektualna svojina, etička pitanja
- Rizici uključuju pogrešne reference i neadekvatnu proverenost rezultata

Pravni okviri i regulative za zaštitu privatnosti

- Pravna zaštita privatnosti korisnika AI alata je izazovna i kompleksna
- Ključna regulativa: evropska Opšta uredba o zaštiti podataka (**GDPR**)
- GDPR postavlja standarde za obradu ličnih podataka, ali ne spominje eksplicitno AI, autonomne sisteme ili big data
- AI sistemi i Big Data zahtevaju nova rešenja za očuvanje informacione privatnosti
- Brzi napredak tehnologije često nadmašuje sposobnost zakona da pruži potpune odgovore na etička i pravna pitanja
- Pravni okviri ne mogu pružiti potpunu zaštitu — uvek postoji jaz između tehnološkog razvoja i regulative

Strategije za zaštitu privatnosti u eri veštačke inteligencije

- Programeri AI modela imaju ključnu ulogu: odgovornost, etika, transparentnost i zaštita privatnosti
- Transparentni i interpretabilni modeli povećavaju poverenje korisnika
- Pravilno rukovanje ličnim podacima poštujući zakonske i etičke norme
- Strategije koje mogu primeniti korisnici:
 - Deidentifikacija – uklanjanje ili sakrivanje ličnih podataka
 - Federativno učenje – treniranje modela lokalno, bez razmene sirovih podataka
 - Generisanje surogata – zamena podataka statistički sličnim vrednostima
 - Diferencijalna privatnost – dodavanje šuma za zaštitu identiteta
 - Lokalni modeli – upotreba laganih modela u bezbednom okruženju
- Cilj: maksimizirati korist AI, a minimizirati rizik po privatnost i sigurnost korisnika

- Veštačka inteligencija ima značajan potencijal i rizike – može manipulirati informacijama, ali i unaprediti produktivnost, kreativnost i pristup znanju.
- Odgovorna i promišljena upotreba AI smanjuje rizike i omogućava društveni i profesionalni napredak.
- AI alati nisu pretnja koju treba izbegavati, već resurs koji, uz obazrivu primenu, doprinosi razvoju i unapređenju svakodnevnog života.
- Ključ uspeha: kombinacija tehničkih, pravnih i edukativnih mera za bezbedno korišćenje tehnologije.

- Automatizacija poslova i oslanjanje na autonomne sisteme otvara nepredviđena pitanja i rizike.
- Povećanje dostupnosti podataka povećava mogućnost manipulacije i ugrožavanja privatnosti.
- Potrebno je stalno unapređivanje regulatornih i etičkih okvira kako bi se pratila brzina tehnološkog razvoja.
- Kontinuirana edukacija korisnika i stručnjaka je neophodna za bezbedno i odgovorno korišćenje AI.

-  Apicella, Andrea, Francesco Isgrò, and Roberto Prevete (2024). *Don't Push the Button! Exploring Data Leakage Risks in Machine Learning and Transfer Learning*. arXiv: 2401.13796 [cs.LG]. URL: <https://arxiv.org/abs/2401.13796>.
-  Chandekar, Harsh (2025). "How Hackers Hide Malicious Prompts in Images to Exploit Google Gemini AI". In: *Towards AI*. URL: <https://towardsai.net/p/machine-learning/how-hackers-hide-malicious-prompts-in-images-to-exploit-google-gemini-ai>.
-  Edwards, Benj (2024). *Stack Overflow users sabotage their posts after OpenAI deal*. URL: <https://arstechnica.com/information-technology/2024/05/stack-overflow-users-sabotage-their-posts-after-openai-deal/>.
-  Gupta, Maanak et al. (2023). "From ChatGPT to ThreatGPT: Impact of Generative AI in Cybersecurity and Privacy". In: *IEEE Access* 11, pp. 80218–80245. DOI: 10.1109/ACCESS.2023.3300381. URL: <https://ieeexplore.ieee.org/abstract/document/10198233>.
-  HAI, Stanford (2024). "Privacy in the AI Era: How Do We Protect Our Personal Information?" In: *Stanford HAI*. URL: <https://hai.stanford.edu/news/privacy-ai-era-how-do-we-protect-our-personal-information>.

-  IBM (2024). "AI Privacy: How to Balance Innovation and Data Protection". In: *IBM*. URL: <https://www.ibm.com/think/insights/ai-privacy>.
-  Jonnagaddala, Jitendra and Zoie Shui-Yee Wong (2025). "Privacy Preserving Strategies for Electronic Health Records in the Era of Large Language Models". In: *npj Digital Medicine*. URL: <https://www.nature.com/articles/s41746-025-01429-0>.
-  Lee, Hao-Ping et al. (2024). *Deepfakes, Phrenology, Surveillance, and More! A Taxonomy of AI Privacy Risks*. arXiv: 2310.07879 [cs.HC]. URL: <https://arxiv.org/abs/2310.07879>.
-  Májovský, Martin et al. (May 2023). "Artificial Intelligence Can Generate Fraudulent but Authentic-Looking Scientific Medical Articles: Pandora's Box Has Been Opened". In: *J Med Internet Res* 25, e46924. ISSN: 1438-8871. DOI: 10.2196/46924. URL: <http://www.ncbi.nlm.nih.gov/pubmed/3725668>.
-  Mitrou, Lilian (2018). "Data Protection, Artificial Intelligence and Cognitive Services: Is the General Data Protection Regulation (GDPR) 'Artificial Intelligence-Proof'?" In: *SSRN Electronic Journal*. URL: <https://ssrn.com/abstract=3386914>.

-  Nazar, S and M R Bustam (July 2020). "Artificial Intelligence and New Level of Fake News". In: *IOP Conference Series: Materials Science and Engineering* 879.1, p. 012006. DOI: 10.1088/1757-899X/879/1/012006. URL: <https://dx.doi.org/10.1088/1757-899X/879/1/012006>.
-  Radanliev, Petar and Omar Santos (2023). *Ethics and Responsible AI Deployment*. arXiv: 2311.14705 [cs.CY]. URL: <https://arxiv.org/abs/2311.14705>.
-  Sartor, Giovanni and Francesca Lagioia (2020). *The Impact of the General Data Protection Regulation (GDPR) on Artificial Intelligence*. Brussels, Belgium: European Parliament, pp. 1–84. ISBN: 978-92-846-6771-0. DOI: 10.2861/293. URL: [https://www.europarl.europa.eu/RegData/etudes/STUD/2020/641530/EPRS_STU\(2020\)641530_EN.pdf](https://www.europarl.europa.eu/RegData/etudes/STUD/2020/641530/EPRS_STU(2020)641530_EN.pdf).
-  WhiteVision (2024). "Privacy in the AI Era: What You Need to Know". In: *WhiteVision*. URL: <https://whitevision.com/en/blog/privacy-in-the-ai-era-what-you-need-to-know>.
-  Wu, Xiaodong, Ran Duan, and Jianbing Ni (2024). "Unveiling security, privacy, and ethical concerns of ChatGPT". In: *Journal of Information and Intelligence* 2.2, pp. 102–115. ISSN: 2949-7159. DOI: <https://doi.org/10.1016/j.jiixd.2023.10.007>. URL: <https://www.sciencedirect.com/science/article/pii/S2949715923000707>.