

Privatnost u doba veštačke inteligencije

Seminarski rad iz kursa Računarstvo i društvo

Marko Lazarević

Matematički fakultet
Univerzitet u Beogradu

October 1, 2025

1. Uvod
2. Curenje podataka u sistemima veštačke inteligencije
3. Manipulacija i lažiranje podataka
4. Pravni okviri i regulative za zaštitu privatnosti
5. Zaključak i budući izazovi

Veštačka inteligencija i njen značaj

- Veštačka inteligencija (eng. *Artificial intelligence* - **AI**)
 - Omogućava mašinama da obavljaju zadatke koji bi inače zahtevali ljudsku inteligenciju
 - Prepoznavanje govora, razumevanje slika, predviđanje ponašanja, donošenje odluka
- Značaj veštačke inteligencije
 - Poslovne primene
 - Automatizacija procesa
 - Edukacija i istraživanje
 - Zabava i kreativnost
- Veštačka inteligencija postala je neizostavni deo današnjice

- Pravna i etička pitanja
- Obrada velike količine podataka
- Rizici
 - Prikupljanje osetljivih podataka
 - Prikupljanje bez pristanka
 - Korišćenje bez dozvole
 - Nadgledanje i pristrasnost
 - Ekstrakcija podataka
 - Curenje podataka
 - Lažiranje podataka

Curenje podataka u sistemima veštačke inteligencije

- Smanjena tačnost modela zbog pogrešnih ili nepotpunih podataka
- Pogrešna evaluacija i optimistični rezultati tokom testiranja
- Gubljenje vremena i resursa zbog ponovnog treniranja modela
- Rizik od curenja poverljivih ili privatnih podataka
- Generativni modeli (npr. ChatGPT) mogu nenamerno izlagati korisničke informacije

Curenje podataka u generativnim alatima

- Primena u odbrani: analiza logova, mrežnog saobraćaja i edukacija korisnika
- Primena u napadu: olakšava pripremu sajber napada čak i bez stručnog znanja
- Primeri stvarnog curenja podataka: Samsung, MediSecure, Stack Overflow/OpenAI
- Opasnost da korisnik izvlači poverljive informacije iz modela
- Preporuka: ograničena upotreba GenAI alata u poslovnom okruženju i pažljivo upravljanje podacima

Lažiranje fotografija (Deepfakes)

- Generativni AI modeli omogućavaju kreiranje uverljivih fotografija i video-snimaka
- Primer: **Clearview.AI** koristi javno dostupne slike za prepoznavanje lica
- Umetnica je otkrila da su njeni medicinski podaci korišćeni u skupovima podataka za treniranje modela **LAION**
- Incident *QTCinderella* — AI deepfake pornografija širi se bez saglasnosti
- Aplikacija **Faceswap** omogućava jednostavno lažiranje lica; dostupna široj javnosti
- Posledice: ozbiljna pretnja privatnosti i integritetu pojedinaca

- AI omogućava širenje lažnih vesti, sada i u video formatu
- Deepfake video može prevariti veliki broj ljudi, što otežava verifikaciju informacija
- Studija: studenti prepoznaju lažne video sadržaje, ali postoji rizik od zavaravanja velikog broja ljudi
- Preporuke: zatvaranje pristupa softverima, edukacija i podizanje svesti o lažnim sadržajima
- AI alati se kontinuirano razvijaju i omogućavaju sve lakšu manipulaciju i lažiranje

- AI može generisati uverljive, ali lažne naučne radove
- Primer: GPT-2 i ChatGPT korišćeni za generisanje lažnih članaka
- AI detektori (Content at Scale, OpenAI) mogu prepoznati generisani tekst, ali nisu savršeni
- Problemi: kredibilitet rada, intelektualna svojina, etička pitanja
- Rizici uključuju pogrešne reference i neadekvatnu proverenost rezultata

Pravni okviri i regulative za zaštitu privatnosti

- Pravna zaštita privatnosti korisnika AI alata je izazovna i kompleksna
- Ključna regulativa: evropska Opšta uredba o zaštiti podataka (**GDPR**)
- GDPR postavlja standarde za obradu ličnih podataka, ali ne spominje eksplicitno AI, autonomne sisteme ili Big Data
- AI sistemi i Big Data zahtevaju nova rešenja za očuvanje informacione privatnosti
- Brzi napredak tehnologije često nadmašuje sposobnost zakona da pruži potpune odgovore na etička i pravna pitanja
- Pravni okviri ne mogu pružiti potpunu zaštitu — uvek postoji jaz između tehnološkog razvoja i regulative

Strategije za zaštitu privatnosti u eri veštačke inteligencije

- Programeri AI modela imaju ključnu ulogu: odgovornost, etika, transparentnost i zaštita privatnosti
- Transparentni i interpretabilni modeli povećavaju poverenje korisnika
- Pravilno rukovanje ličnim podacima poštujući zakonske i etičke norme
- Strategije koje mogu primeniti korisnici:
 - Deidentifikacija – uklanjanje ili sakrivanje ličnih podataka
 - Federativno učenje – treniranje modela lokalno, bez razmene sirovih podataka
 - Generisanje surogata – zamena podataka statistički sličnim vrednostima
 - Diferencijalna privatnost – dodavanje šuma za zaštitu identiteta
 - Lokalni modeli – upotreba laganih modela u bezbednom okruženju
- Cilj: maksimizirati korist AI, a minimizirati rizik po privatnost i sigurnost korisnika

- Veštačka inteligencija ima značajan potencijal i rizike – može manipulirati informacijama, ali i unaprediti produktivnost, kreativnost i pristup znanju.
- Odgovorna i promišljena upotreba AI smanjuje rizike i omogućava društveni i profesionalni napredak.
- AI alati nisu pretnja koju treba izbegavati, već resurs koji, uz obazrivu primenu, doprinosi razvoju i unapređenju svakodnevnog života.
- Ključ uspeha: kombinacija tehničkih, pravnih i edukativnih mera za bezbedno korišćenje tehnologije.

- Automatizacija poslova i oslanjanje na autonomne sisteme otvara nepredviđena pitanja i rizike.
- Povećanje dostupnosti podataka povećava mogućnost manipulacije i ugrožavanja privatnosti.
- Potrebno je stalno unapređivanje regulatornih i etičkih okvira kako bi se pratila brzina tehnološkog razvoja.
- Kontinuirana edukacija korisnika i stručnjaka je neophodna za bezbedno i odgovorno korišćenje AI.

Pitanja?