

Zastita od veštačke inteligencije u vizuelnim umetnostima

Dimitrije Matovic 202/2020

A dark blue diagonal gradient bar that starts from the bottom left and extends towards the top right, covering the lower half of the slide.

Svaki dan na X je divan dan!

Elon Musk je dodao polisu na platformi Tviter koja dopušta veštačkoj inteligenciji da uči kako da generiše od bilo kojih slika.



Šta je VI?

Mašina se može proglasiti pametnom ukoliko je nemoguće razaznati razliku između nje i čoveka u toku razgovora sa nekim slučajno izabranim posmatračem.




Potrebno je postaviti pitanje kako je moguće da mašina nauči kako da kreira nešto poput umetnosti kao čovek. Da bismo odgovorili na to pitanje, potrebno je ukratko objasniti kako AI vidi crteže.

Šta je VI?

Masovna digitalizacija slika i umetnosti u poslednjih nekoliko godina je omogućila njihovu dostupnost na internetu

Kao što svaki potez četkice na slici ima svoju ulogu, tako i svaki broj u njenoj numeričkoj reprezentaciji ima potencijal koji treba istražiti.



Koraci:

1. Pošto ih digitalizujemo potrebno je i da ih klasifikujemo pomoću konvolutnih mreža
2. Koristimo duboke neuronske mreže kako bismo detektovali objekte na slici poput lica, vaza, stolica...
3. Na osnovu ovoga, dobijamo skup podataka za treniranje i testiranje



Glaze predstavlja alat koji štiti umetnike od neovlašćenog korišćenja njihovog stila crtanja za treniranje AI modela i njihovo generisanje slika.

Ukoliko imamo rad X jednog stila, sistem ga transformiše u sliku koja ima isti sadržaj, ali drugačiji stil.



Kako funkcioniše?

1. Korak - Odabir ciljnog stila
2. Korak - Style Transfer
3. Računanje perturbacije
4. Objavljivanje

Generativni modeli imaju kontinualni izlazni prostor tj. svako pomeranje u feature reprezentaciji menja generisanu sliku. Čak i najmanje pomeranje stila može da napravi nekoherentu mešavinu dva stila.

$\min_{\delta x} \text{Dist}(\Phi(x + \delta x), \Phi(\Omega(x, T)))$ pod uslovom $|\delta x| < p$
 $\alpha * \max(\text{LP IP } S(\delta x) - p, 0)$

Mimicry je upotrebljiv samo ako je dovoljno sličan originalnom stilu slike.

x	T	δx	Φ	$\Omega(x, T)$	$ \delta x $	p	α	$\max(*, 0)$
Input slika	Ciljni stil	Cloak pertubacije	Karak. prostor	Style transfer verzija	metrika	Max dozvoljena promena	Faktor penalizacije	RELU funkcija



Nightshade predstavlja napredni alat za trovanje podataka koji se koriste za treniranje VI-a.

Usmeren je na difuzne modele koji generišu slike iz teksta.

Ukoliko korisnik traži sliku psa, model će generisati sliku mačke.

Ciljevi su sledeći:

- Efikasnost uz mali broj uzoraka
- Izbegavanje detekcije




Kako funkcioniše?

1. Korak - Izbor otrovnih slika
2. Korak - Generisanje Anchor slike
3. Korak - Konstruisanje otrovnih slika

$\min D(F(x_t + \delta), F(x_a))$ uz uslov : $|\delta| < p$
 $\min \|F(x_t + \delta) - F(x_a)\|_2 + \alpha \cdot \max(\delta - p, 0)$

x_t	Originalna slika
x_a	Sidrena slika
δ	Nevidljiva izmena vrednosti piksela
F	Ekstraktor karakteristika text-to-image modela
D	Funkcionalno rast.
p	Budžet poremećivanja
$\alpha \cdot \max(\delta - p, 0)$	Kazneni član

Kako funkcionišu zajedno?




Glaze predstavlja štit iliti ogrtač same slike koja omogućava da zaštiti stil umetnika dok Nightshade direktno truje i napada modele veštačke inteligencije. Zajedno prave dvoslojevitú zaštitu crteža.

Prvo se koristi Nightshade. Umetnik ubacuje svoju sliku u Nightshade i bira nivo trovanja. Zatim se primenjuje Glaze na već otrovanu sliku. Ovim korakom umetnik dodatno maskira svoj stil, čineći ga težim za interpretaciju i imitaciju.

Ukoliko bismo uradili obrnuto imalo bi malo manjeg uticaja.

Da li je svet protiv ili za generativni AI?



AOC presses EPA administrator on data centers' impact on clean drinking water



Pitanja za publiku

1. Kakav je vaš stav o generativnom VI-u pre i posle? Ako ste promenili mišljenje, objasnite zašto.
2. Da li je po vašem mišljenju etički korektno da se modeli veštačke inteligencije treniraju nad crtežima koji su umetnici stvorili?
3. Ako biste imali svoj biznis, da li biste platili umetnika da vam dizajnira vaš logo ili biste platili osobu da vam napiše dovoljno dobar prompt?

Hvala na pažnji! :)