

Zastita od veštačke inteligencije u vizuelnim umetnostima

Dimitrije Matović 202/2020

April 2026

Sadržaj

1	Uvod	3
1.1	Šta je veštačka inteligencija?	3
1.2	Koraci za treniranje veštačke inteligencije	4
2	Alat - Glaze	5
2.1	Kako funkcioniše algoritam Glaze-a?	5
2.2	Dokaz funkcionisanja	6
3	Alat - Nightshade	6
3.1	Kako funkcioniše algoritam Nightshade-a?	7
3.2	Dokaz funkcionisanja	8
4	Kako Glaze i Nightshade funkcionišu u paru?	8
5	Trenutni pogled sveta na generativni AI	9
6	Zaključak	10

1 Uvod

"Svaki dan na X je divan dan!" - Elon Musk 2024. Elon Musk je dodao polisu na platformi Tviter koja dopušta veštačkoj inteligenciji da uči kako da generiše od bilo kojih slika. To takođe uključuje umetnike i njihova dela koja su postavljena na platformi. Zatim je postavio sliku čime je hteo da pokaže kako VI može da "nauči i kreira umetnost".



Kao što možemo da vidimo, na ovoj slici se svakakve stvari desavaju. Čovek bi trebalo da stoji na terasi, ali ovde vidimo da lebdi u vazduhu dok ljudi ispod njega šetaju. Ljudi voze moderne automobile i ljudi takođe šetaju po ulici. Na pozicijama gde bi trebalo prozori da budu su samo dizorijentisane mrljotine.

Elon Muskova slika predstavlja VI mešavinu Kubertove *Očajnik* (Le Désespéré) (1843-45) i Kajbotovog *Čoveka na balkonu* (Man on the Balcony) (1880). Kao što se da primetiti, kola iz 21. veka nisu postojala u momentu kada su ovi crteži bili napravljeni iako su "na-

Pre nego što uopšte možemo da kritikujemo kako je ova slika napravljena, potrebno je da se zapitamo kakav je proces kreiranja slike preko veštačke inteligencije.


1.1 Šta je veštačka inteligencija?

Teško je definisati šta je veštačka inteligencija sama po sebi. Alan Tjuring je u svojoj skripti "Computing machinery and intelligence" rekao da se mašina može proglasiti pametnom ukoliko je nemoguće razaznati razliku između nje i čoveka u toku razgovora sa nekim slučajno izabranim posmatračem. [9] U današnje vreme bismo mogli reći da je mašina pametna ukoliko može da govori, razmišlja i postupa na sličan način kao što bi čovek uradio.

Dosta novih inicijativa kreće iz same teme kako AI može da napravi umetnost, ali razumevanje i uvažavanje toga šta je umetnost može samo čovek da potvrdi. Potrebno je postaviti pitanje kako je moguće da mašina nauči kako da kreira nešto poput umetnosti kao čovek. Da bismo odgovorili na to pitanje, potrebno je ukratko objasniti kako AI vidi crteže.

Masovna digitalizacija slika i umetnosti u poslednjih nekoliko godina je omogućila njihovu dostupnost na internetu. Pored toga imamo i digitalnu umetnost koja takođe predstavlja novu skup podataka koje je neophodno istražiti. Fizikalna i digitalna slika postoje u različitim materijalnim oblastima, ali pokazuju istu složenu strukturu podataka koja opisuje tu sliku. Kao što svaki potez četkice na

slici ima svoju ulogu, tako i svaki broj u njenoj numeričkoj reprezentaciji ima poencijal koji treba istražiti. Bitno je naglasiti da ćemo nad tim numeričkim reprezentacijama primeniti različite naprednije algoritme kojim otvaramo novu perspektivu o samoj digitalizovanoj slici.



Slika 1: Proces digitalizacije podataka

Gornja slika ilustruje proces od digitalizacije do kvantitativne analize, otkrivanja znanja i vizuelizacije korišćenjem računarskih metoda. Rezultati istraživanja dobijeni iz završne faze ovog procesa često se koriste za poboljšanje funkcionalnosti repozitorijuma i onlajn kolekcija dodavanjem naprednih načina istraživanja sadržaja.

1.2 Koraci za treniranje veštačke inteligencije

Pošto su slike postale digitalizovane i sada predstavljaju vrstu podataka, potrebno je da uradimo sledeći korak, što je klasifikacija. Tokom poslednje decenije, najbitniji izazov je bio automatizovati klasifikaciju umetničkih dela na osnovu kategorija kao što su umetnik, stil i žanr. Korišćenjem konvolutnih neuronskih mreža, dobijen je ogroman napredak u poboljšanju tačnosti klasifikacije. Pokazano je da upotreba ovog modela ima najbolje preformanse u odnosu na ostale baš zbog toga što je napravljen tako da specifično obrađuje atribute slika (poput boje ili ivica). [3]

Pored klasifikacije, korišćenje dubokih neuronskih mreža se pokazalo kao jako korisno u istraživanju umetničkih radova. Pogodan je zbog toga što može da prepozna objekte, lica i različite motive samog crteža. Pokazano je da klasifikatori obučeni korišćenjem konvolutnih neuronskih mreža mogu, sa velikim uspehom, da pronađu slike koje sadrže određene objekte. Kasnije studije su se bavile problemom određivanjem položaja objekta na slici. [2] Pored toga, jedan od bitnijih istraživanja jeste bilo kako da dubokim neuronskim mrežama prepoznamo lice čoveka. Neki istraživači su otišli malo dublje na tu temu do te mere da su radili analizu i klasifikaciju ljudskog lica na osnovu njihovog pola i dodatnih osobina. [6]

Na osnovu svih ovih podataka, dobijamo skup podataka koje kasnije koristimo za treniranje i testiranje čime dobijamo AI umetnost.

Sada znamo ukratko o tome kako veštačka inteligencija funkcioniše u ovoj sferi. Zbog toga, možemo da govorimo o tome kako da se zaštitimo od njega. Postoji nekoliko alata za zaštitu crteža od AI napada. Ja ću konkretno govoriti o Glaze i Nightshade-u. U ovom tekstu se najviše pozivam na radove "Glaze: Protecting artists from style mimicry by Text-to-Image models" i "Nightshade: Prompt-specific poisoning attacks on text-to-image generative models" autora Šon Šan (Shawn Shan), Džena Krajan (Jenna Cryan), Emili Venger (Emily Wenger), Haitao Džong (Haitao Zheng), Rana Hanoka (Rana Hanocka) i Ben Džao (Ben Y. Zhao).

2 Alat - Glaze

Glaze predstavlja alat koji štiti umetnike od neovlašćenog korišćenja njihovog stila crtanja za treniranje AI modela i njihovo generisanje slika. Napadi "style mimicry" funkcionišu tako što model uradi "fine-tuning" na umetničkim delima određenog autora, a zatim generiše nova dela u tom stilu bez dozvole. Ideja je da umesto da blokiramo trening modela, Glaze mami model da nauči pogrešan stil tako što daje nevidljive perturbacije na samom originalnom delu.

Glaze koristi **style transfer** da bi izolovao stilske komponente slike. Ukoliko imamo rad X jednog stila, sistem ga transformiše u sliku koja ima isti sadržaj ali drugačiji stil. Na primer, ako je slika bila u Baroko stilu, možemo je prebaciti u stil klasicizma. Ova transformacija služi kao ciljna "maska" za računanje perturbacija.

Perturbacija se optimizuje tako da u prostoru karakteristika modela, slika liči na style-transfer verziju. Ovo navodi AI na pogrešne zaključke i učenje.

2.1 Kako funkcioniše algoritam Glaze-a?

1. Korak - Odabir ciljnog stila

Algoritam prolazi kroz javni dataset umetnika, računa centroid svakog stila Φ . Zatim, algoritam računa centroid umetnika i na osnovu prethodnih rezultata bira kandidate čija je udaljenost od umetnikovog centroida između 50. i 75. percentila. Nasumično bira stil T iz tog skupa kandidata.

2. Korak - Style Transfer

Za svako delo X se primenjuje trenirani model Ω koji će generisati style transfer verziju $\Omega(x, T)$. Sadržaj slike ostaje isti, ali stil se menja.

3. Korak - Računanje perturbacije

U ovom koraku računamo ogrtač ili cloak. On se dobija rešavanjem sledećeg optimizacionog problema:

$$\min \text{ over } \delta_x \text{ Dist}(\Phi(x + \delta_x), \Phi(\Omega(x, T))) \text{ pod uslovom } |\delta_x| < p \quad (1)$$

gde je x input slika, T ciljni stil, δ_x cloak perturbacije, Φ karakteristični prostor modela, $\Omega(x, T)$ style transfer verzija modela, $|\delta_x|$ LPIPS metrika i p maksimalno dozvoljena vizuelna promena.


Ovo možemo proširiti dodavanjem kaznenog člana. Na originalni račun distance dodajemo $\alpha * \max(LPIPS(\delta_x) - p, 0)$ gde je α faktor penalizacije koji kontroliše koliko je jak uslov vidljivosti perturbacije i $\max(*, 0)$ koja je RELU funkcija tj. kazna koja postoji samo ako perturbacija preskoči budžet p .

4. Korak - Objavljivanje

Umetnik objavljuje $x + \delta_x$ umesto originala. Za ljudsko oko slika izgleda nepromenjeno ali AI modeli je koriste za trening i nauče pogrešan stil.

2.2 Dokaz funkiconisanja

Generativni modeli imaju kontinualni izlazni prostor tj. svako pomeranje u feature reprezentaciji menja generisanu sliku. Čak i najmanje pomeranje stila može da napravi nekoherentu mešavinu dva stila, kao na primer ako pomešamo Van Gogov stil sa realizmom. Ovo direktno ugrožava mimicry jer je ona upotrebljiva samo ako je dovoljno slična originalnom stilu slike. Malo mešanje sa stilom T unosi dovoljno konfuzije mimicry-u da ona postaje neupotrebljiva, čak i kada model ima pristup delovima slike koje nemaju ogrtač oko sebe.[4]



Slika 2: Primer rada Glaze-a

3 Alat - Nightshade

Nightshade predstavlja napredni alat za trovanje podataka koji se koriste za treniranje VI-a. Usmeren je na difuzne modele koji generišu slike iz teksta. Cilj ovog alata je da ubaci mali broj skoro nevidljivo izmenjenih slika u trening skup modela. Samim tim, potencira na pogrešno ponašanje modela. Na primer, ukoliko korisnik traži sliku psa, model će generisati sliku mačke.

Ciljevi napada su sledeći:

- Efikasnost uz mali broj uzoraka - Pošto napadač ne kontroliše sa koje stranice model uzima resurse, veliki deo otrovnih slika neće biti preuzet. Zato želimo da otvorne slike koje se preuzmu imaju što veći uticaj na trening skup.

- Izbegavanje detekcije - Otrovni podaci moraju izgledati prirodno. Tekst i slika moraju biti i vizuelno i semantički usklađeni. U suprotnom, mogu biti prepoznati od strane automatskih algoritama ili od napadača koji ga proverava.

3.1 Kako funkcioniše algoritam Nightshade-a?

1. Korak - Izbor otrovnih tekstualnih opisa

Iz skupa prirodnih parova (tekst, slika) koji opisuju ciljni koncept Y , biraju se opisi koji su semantički najbliži tom konceptu. Bliskost se meri kosinusnom sličnošću. Na primer, ako je $Y = \text{"pas"}$, biraju se opisi "slika psa" ili "portret psa", tj. oni koji najjasnije aktiviraju taj koncept u modelu. Nasumično uzorkovanje sprečava odbrambene sisteme da otkriju napad.

2. Korak - Generisanje Anchor Images

Koristeći generativni model M , generiše se skup prototipskih slika koncepta A , koncept koji je semantički nepovezan sa Y . Na primer, ako je $Y = \text{"pas"}$, bira se $A = \text{"mačka"}$. Napadač daje prompt modelu: "a photo of cat" i model generiše svoju idealnu, prototipsku mačku. To je slika za koju model zna da je mačka. Njen vektor u prostoru karakteristika je savršen predstavnik koncepta "mačka" iz perspektive tog modela. Zatim, napadač uzme fotografiju psa i polako je menja (piksel po piksel, nevidljivo) sve dok njen vektor u prostoru karakteristika ne postane što bliži vektoru sidrene slike. Vizuelno je još uvek pas ali model ga "oseća" kao mačku.

3. Korak - Konstruisanje otrovnih slika

Za svaki odabrani opis t , koji opisuje Y , uzima se njegova prirodna slika x_t i poremetićemo je formulom:

$$\min D(F(x_t + \delta), F(x_a)) \text{ uz uslov : } |\delta| < p \quad (2)$$

Gde je x_t originalna slika, x_a sidrena, δ nevidljiva izmena vrednosti piksela koja se dodaje na x_t , F ekstraktor karakteristika text-to-image modela, D funkcija rastojanja (npr. euklidsko) i p budžet poremećivanja (gornja granica vizuelne promene)

U praksi, umesto striktnog ograničenja koristimo penalizacionu metodu koja pretvara uslov u deo cilja.

$$\min \|F(x_t + \delta) - F(x_a)\|^2 + \alpha \cdot \max(\delta - p, 0) \quad (3)$$


$\|F(x_t + \delta) - F(x_a)\|^2$ predstavlja kvadratno rasotanje između karakteristika otrovne i sidrene slike. Minimizovanjem ovog izraza osiguravamo da model vidi otvornu sliku slično kao sidrenu.

$\alpha \cdot \max(\delta - p, 0)$ - Kazneni član koji se aktivira samo kada preturbacija prekorači dozvoljeni prag p .

Rezultat je slika koja izgleda kao normalna fotografija psa, ali čiji unutrašnji zapis u modelu odgovara mački. Kada model nauči na ovakvim podacima, svaki put kada korisnik zatraži "psa", model generiše nešto što liči na mačku.

3.2 Dokaz funkcionisanja

Obični trening podaci su jako heterogeni i raznovrsni, kao na primer različite fotografije pasa snimljene iz različitih uglova, sa različitim osvetljenjem... Gradijentna ažuriranja koji dolaze od tih slika tokom treninga se poništavaju međusobno jer vuku model u različitim pravcima. Nightshade rešava ovaj problem. Svi otrovni tekstualni opisi su skoncentrisani na isti ključni koncept (bez šuma), a sve sidrene slike su generisane na isti način. To znači da svi otrovni uzorci vuku model u identičnom pravcu. Efekat je jako konzistentan, omogućava da i mali broj ovakvih uzoraka može nadjačati stotine hiljada legitimnih slika.[5]



Slika 3: Primer slika sa filterom



Slika 4: Primer uticaja slika trovanja

4 Kako Glaze i Nightshade funkcionišu u paru?

Kao što kod linearne regresije mere kvaliteta RMSE i R^2 nisu samostalno dovoljne i dopunjuju jedno drugog, tako Nightshade i Glaze rade zajedno u paru i preporučuje se da se koriste obe odjednom.

Glaze predstavlja štit iliti ogrtač same slike koja omogućava da zaštiti stil umetnika dok Nightshade direktno truje i napada modele veštačke inteligencije. Zajedno prave dvoslojevitú zaštitu crteža.

Prvo se koristi Nightshade. Umetnik ubacuje svoju sliku u Nightshade i bira nivo trovanja. Zatim se primenjuje Glaze na već otrovanu sliku. Ovim korakom umetnik dodatno maskira svoj stil, čineći ga težim za interpretaciju i imitaciju. Ovaj redosled je važan zato što Glaze štiti stil preko već izmenjene semnatike slike. Ukoliko bismo uradili obrnuto imalo bi malo manjeg uticaja. Glaze bi promenio vizuelne obrasce koje Nightshade koristi da bi zbunio i otrovao model. Na promenjeni stil bismo menjali karakteristike slike i Nightshade bi imao manju kontrolu nad time kako model vidi sadržaj. Efekat trovanja se može smanjiti zbog toga.

Ovi alati nažalost nisu savršeni. Njihov efekat zavisi od toga kako se modeli treniraju i da li prepoznaju ili ignorišu ovakve perturbacije.

5 Trenutni pogled sveta na generativni AI

Trenutna pozicija AI-a je vrlo diskutabilna. Do skorije, dosta kompanija poput NVIDIA i Microsofta su u potpunosti bili za korišćenje veštačke inteligencije u generativnom smislu. NVIDIA je čak napravila DLSS5 grafički alat koji u realnom vremenu utiče na samu grafiku video igara i koristi generativni AI kako bi dodali filtere na samu igricu. To utiče i na sam enterijer, eksterijer i anatomiju lica čoveka. Dosta gejmera i umetnika se pobunilo protiv ovog alata jer su neke likove promenili do te mere da više ne izgledaju prirodno. Takođe su se pobunili zato što potkopava umetničku slobodu, trud i rad dizajnera video igara. [1] CNN je na nacionalnoj televiziji objavio kako Microsoft i NVIDIA preispituju svoje odluke o korišćenju AI-a. Došlo je do tih mera da je Microsoft zabranio svojim radnicima prekomerno korišćenje AI-a, a NVIDIA je rekla da ih više košta da plate AI nego da imaju tim od pravih ljudi.



Slika 5: Proces digitalizacije podataka

Papa Lav XIV je 15. maja 2026. godine potpisao svoju prvu Encikliku pod imenom "Magnifica Humanitas" u kojoj govori o tome da veštačka inteligencija treba služiti čovečanstvu. Enciklika se fokusira na to kako da očuva ljudsko dostojanstvo u eri veštačke inteligencije. Na televiziji je govorio o tome kako je veštačka inteligencija zlo protiv čovečanstva ukoliko se koristi u pogrešne svrhe.

Pored toga što generativni AI kradе slobodu i originalnost samih umetnika bez razgovora sa njima, genera-



ativni AI proizilazi iz Data Centra koji uništavaju pijaću vodu. Velike korporacije prave Data Centre koje uništavaju nju do te mere da voda sa česme postaje braon i zagađena. Koriste toliko resursa da ljudi rapidno počinju da gube pristup normalnoj vodi i moraju da kupuju flaširanu vodu da bi je pili ili održali osnovnu higijenu.[7]

6 Zaključak

Razvoj generativne veštačke inteligencije je doneo velike promene u oblasti vizuelnih umetnosti, otvarajući vrata o ozbiljnim etičkim i pravnim pitanja. Kao što je prikazano, modeli veštačke inteligencije funkcionišu na osnovu velikih količina podataka. Često se uzimaju podaci o crtežima bez eksplicitne dozvole autora, čime se direktno dovodi u pitanje zaštita autorskih prava.

Alati poput Glaze i Nightshade predstavljaju prve konkretne korake ka zaštiti umetnika u digitalnom okruženju. Dok Glaze otežava imitaciju umetničkog stila, Nightshade aktivno utiče na ponašanje modela kroz trovanje podataka, a njihova kombinovana upotreba pruža složeniji i efikasniji vid odbrane. Ipak, ovi alati nisu konačno rešenje, jer njihova efikasnost zavisi od načina treniranja modela i budućih tehnoloških unapređenja. Kreatori ovih alata se iz dana u dan zalažu da ih naprave boljim i pogodnijim za korišćenje. Uvek će postojati momenti kada Glaze i Nightshade neće biti dovoljni. Stoga, cilj kreatora je da produže njihov trenutni rok trajanja koliko god je to moguće.

Pored tehničkih izazova, neophodno je sagledati i širi društveni kontekst. Debata o ulozi veštačke inteligencije pokazuje duboku podeljenost između tehnološkog napretka i očuvanja ljudske kreativnosti. Dovodi se u pitanje i ekološke posledice nastale od strane infrastruktura koje podržavaju AI sisteme.

U budućnosti će biti ključno pronaći balans između inovacije i regulacije. Zaštita umetnika se ne može osloniti isključivo na tehnička rešenja, već zahteva i pravni okvir, transparentnost u razvoju AI sistema i veću svest o vrednosti originalnog ljudskog stvaralaštva. Veštačka inteligencija treba da bude alat koji pruža pomoć čoveku, a ne da ga zameni i ograniči njegovu kreativnost.

Literatura

- [1] Kindrat Beregovyi i Thomas Butkiewicz. “Visual Integrity in the Age of AI: An Evaluation of DLSS and DLAA in Geospatial Visualization”. U: *2025 IEEE Visualization and Visual Analytics (VIS)*. IEEE. 2025., str. 291–295.
- [2] Elliot J Crowley i Andrew Zisserman. “The art of detection”. U: *European conference on computer vision*. Springer. 2016., str. 721–737.
- [3] Sergey Karayev i dr. “Recognizing image style”. U: *arXiv preprint arXiv:1311.3715* (2013.).
- [4] Shawn Shan i dr. “Glaze: Protecting artists from style mimicry by {Text-to-Image} models”. U: *32nd USENIX Security Symposium (USENIX Security 23)*. 2023., str. 2187–2204.
- [5] Shawn Shan i dr. “Nightshade: Prompt-specific poisoning attacks on text-to-image generative models”. U: *2024 IEEE symposium on security and privacy (SP)*. IEEE. 2024., str. 807–825.
- [6] Gjorgji Strezoski i Marcel Worring. “Omniart: a large-scale artistic benchmark”. U: *ACM Transactions on Multimedia Computing, Communications, and Applications (TOMM)* 14.4 (2018.), str. 1–21.
- [7] Victor Tangermann. “Woman Says Zuckerberg’s AI Data Center Filled Her Tap Water With Sediment”. U: *Futurism* (2025.). URL: <https://futurism.com/the-byte/woman-meta-ai-data-center-tap-water-sediment>.
- [8] The Art Newspaper. *Elon Musk serves up disconcerting AI art*. 2024. URL: <https://www.theartnewspaper.com/2024/11/26/elon-musk-loves-his-ai-art-memes>.
- [9] Alan M Turing. “Computing machinery and intelligence”. U: *Parsing the Turing test: Philosophical and methodological issues in the quest for the thinking computer*. Springer, 2007., str. 23–65.