

Sistemiški gubitak podataka u velikim jezičkim modelima kolaps modela i algoritamska diskriminacija

Mila Gligorić

82/22

Teme

Tehnički / matematički
razlozi kolapsa

Homogenizacija
podataka i nuspojave
kolapsa

Socioetički aspekti
kolapsa modela

Budućnost i moguća
rešenja

Kolaps modela

Definicija pojma Kolaps modela

Pojam definisan 2023. godine u radu "The Curse of Recursion: Training on Generated Data"

Nastanak kolapsa modela

Nastaje kada se AI modeli iznova i iznova treniraju na sintetičkim podacima (podacima takođe generisanim od strane AI modela)

Važnost proučavanja kolapsa modela

Razumevanje i proučavanje kolapsa modela - ključno za očuvanje raznolikog interneta i kvaliteta podataka

Važnost kolapsa modela

Veliki jezički modeli

(GPT, Gemini i sl.) - trajni i relevantni igrači u ekosistemu online teksta i slike

Ključno pitanje o AI generisanom sadržaju

Šta se dešava kada tekstovi generisani AI-jem preplave internet i „zagađuju“ ga?

Posledice kolapsa modela

Kolaps modela

->

degradacija kvaliteta podataka

->

(ne)održivost treniranja modela na podacima uzetim sa web-a

(web scraping)

Prelaz sa ljudskih na sintetičke podatke

Početak treninga modela θ

Model θ se trenira na skupu H , koji sadrži samo ljudski tekst iz stvarne raspodele $p(x)$

Zagađenje interneta sintetičkim tekstom

Sintetički tekst preplavi internet, a sledeće generacije modela nemaju pristup čistom H (zagađenje interneta)

Rekurzivni proces generisanja i treniranja

Rekurzija: za $t = 1..n$, model θ_{t-1} generiše skup H_t i model θ_t ga tretira kao ground truth *

*(verifikovana i tačna informacija koja se koristi kao zlatni standard pri treniranju, validaciji i testiranju modela)

Glavne 3 vrste grešaka (koje dovode do kolapsa)

Greška statističkog uzorkovanja

Retki događaji (tail events) ređe ulaze u naredne generacije

Greška funkcionalne aproksimacije

Konačan broj parametara ne može savršeno opisati složene raspodele

Greška funkcionalne ekspresivnosti

Ograničenja optimizacije (pr. lokalni minimumi) uvode sistemsku pristrasnost

Long-tailed raspodele i „potkresivanje repa“

Ljudski jezik nije jednostavna Gaussova raspodela, ima dug rep (long-tailed distribution)

Rekurzivno učenje smanjuje ukupnu grešku tako što pojačava delove sa najvećom gustinom verovatnoće

Retke informacije, stručna terminologija i manjinski jezici bivaju potisnuti

Faze degradacije raspodele

Faza 1: pomeranje gustine ka sredini

Varijansa opada i izlazi postaju uniformniji

Faza 2: potkresivanje dugog repa

Informacije niske verovatnoće ispadaju iz generisanog skupa

Povratak odsečenog repa

Kako bi se odsečeni rep vratio neophodan je priliv novih ljudskih podataka.

Entropija kao merilo gubitka raznolikosti

Entropija i generisanje teksta

U generisanju teksta entropija opisuje nepredvidivost, bogatstvo i raznovrsnost odziva modela

Promena entropije tokom rekurzivnog učenja

Tokom rekurzivnog učenja entropija stabilno opada:

$$H(X) > H(X_1) > \dots > H(X_n)$$

Rani kolaps



Gramatička ispravnost uz gubitak finese

Tekst je gramatički ispravan, gube se samo finese



Nestanak retkih reči i ponavljanje prosečnih fraza

Retke reči i specifični izrazi nestaju, a model počinje da ponavlja uvek iste, prosečne fraze



Opasnost rane faze kolapsa

Ova faza je najopasnija jer klasični automatski testovi često ne primete degradaciju na vreme

Kasni kolaps

Kasni kolaps i entropija

Nastaje kada entropija gotovo nestane

Gubitak sposobnosti modela

Model gubi sposobnost smislenog izražavanja

Posledice kasnog kolapsa

Generiše se tekst koji je potpuno besmislen, ponavlja se isto više puta itd.

Nuspojave statističke optimizacije

Društvene posledice fenomena

Osim matematičkih, ovaj fenomen ima i društvene posledice

Neželjeni efekti učenja

Homogenizaciji i cenzura

Kao neželjeni
efekti učenja

Manifestacije posledica

Posledice se manifestuju
kroz jezik,
smanjenje originalnosti i diverziteta,
plasiranje podataka iz uske tačke
gledišta
manjak poverenja u iste

Marginalizacija retkih jezika

Dominacija engleskog jezika

Manji jezici (uključujući srpski) ulaze u „rep“ raspodele zbog dominacije engleskog.

Optimizacioni modeli i „šum“

Manje zastupljeni izrazi i oblici se od strane optimizacionih modela registruju kao „šum“.

Gubitak lokalne sintakse u generisanom tekstu

Generisani tekstovi na manjim jezicima gube lokalnu sintaksu – prevodi su mehanički i bezlični.

Globalna lingvistička homogenizacija

Utjecaj centraliziranih AI modela

Centralizovani AI modeli postepeno brišu raznolikost jezika i kultura

Prijetnja opstanku jezika

Smanjuje se šansa da retki jezici i dijalekti opstanu u digitalnom prostoru

LLM – stohastički papagaj

LLM-ovi kao statistički sistemi bez razumevanja značenja
Procenjuju verovatnoću sledeće reči na osnovu prethodnih tokena

Etički rizici i pouzdanost

Odsustvo pravog razumevanja povećava etičke rizike, posebno kada su podaci pristrasni.

Nije moguće osloniti se na model da donese "tačnu" odluku, ako mu to statistički nije u interesu

Učvršćivanje predrasuda putem kolapsa

Početni podaci i predrasude

Početni podaci sadrže istorijske predrasude ili stereotipe -> rekurzivno treniranje ih ne ispravlja

Smanjenje varijanse i učvršćavanje pristrasnosti

Smanjenje varijanse -> učvršćavanje pristrasnih obrazaca kao apsolutne istine

Nejednakost u podacima i njen uticaj

Nejednakost u početnim podacima -> dugoročna (nepopravljiva) nejednakost u generisanom sadržaju

Strategije ublažavanja

Problematika rasta modela

Problem se ne može rešiti pukim povećanjem veličine modela ili dodavanjem novih parametara

Ključna strategija za rešenje

Rešenje: kontrola porekla i kvalitet podataka pre ulaska u trening

Data Provenance

= Praćenje porekla podata

Trag o tome kako su prikupljeni,
čišćeni i menjani.

Cilj praćenja porekla podataka :

Blagovremeno prepoznavanje AI generisanog teksta.

Odvajanje istog od ljudskog pre treninga, kako bi se izbegla
rekurzivna petlja koja vodi ka kolapsu.

Pametnije tehnike uzorkovanja

Čuvanje manje zastupljenih jezika i domena

Primena tehnika uzorkovanja koje namerno čuvaju manje zastupljene jezike i stručne domene

Smanjenje rizika nestajanja long-tailed

Smanjuje se rizik nestajanja long-tailed kroz generacije

Očuvanje raznolikosti za stabilnu entropiju

Pomaže da se očuva raznolikost koja je ključna za stabilnu entropiju

Ljudski tekst kao neobnovljiv resurs



Autentični ljudski tekst kao resurs

Autentični ljudski tekst na internetu treba posmatrati kao dragocen i neobnovljiv resurs



Zaštita od AI sadržaja

Ključno – aktivna zaštita od nekontrolisanog zagađenja generičkim AI sadržajem



Očuvanje raznolikosti

Očuvanje raznolikosti = zaštita održivosti i granica same tehnologije

Pitanja ključna za dalji razvoj AI-a

Meranje i sprečavanje degradacije kvaliteta

Kako meriti i sprečiti degradaciju kvaliteta pre nego što postane neprimetna u ranim fazama?

Uspostavljanje standarda za Data Provenance

Kako uspostaviti standarde za Data Provenance pri prikupljanju podataka?

Balans između profitnih motiva i društvenog razvoja

Kako uspostaviti balans između profitnih motiva i potrebe da se tehnologija razvija za društvo, a ne protiv njega?

Put ka rešenju problema

Ne oslanjati se na povećanje modela

Ne oslanjati se na povećanje modela, već promeniti način prikupljanja i vrednovanja podataka

Data Provenance

Čuvanje istorije i porekla podataka

Pametno uzorkovanje i zaštita ljudskog teksta

Pametno uzorkovanje + tretiranje ljudskog teksta kao resurs koji zahteva aktivnu zaštitu

Glavna literatura

Shumailov i saradnici (2023)

The curse of recursion: Training on generated data makes models forget.

<https://doi.org/10.48550/arXiv.2305.17493>

Dohmatob i saradnici (2024)

How bad is training on synthetic data? A statistical analysis of language model collapse.

<https://doi.org/10.48550/arXiv.2404.01502>

Bender i saradnici (2021)

On the Dangers of Stochastic Parrots: Can Language Models Be Too Big?

<https://doi.org/10.1145/3442188.3445922>